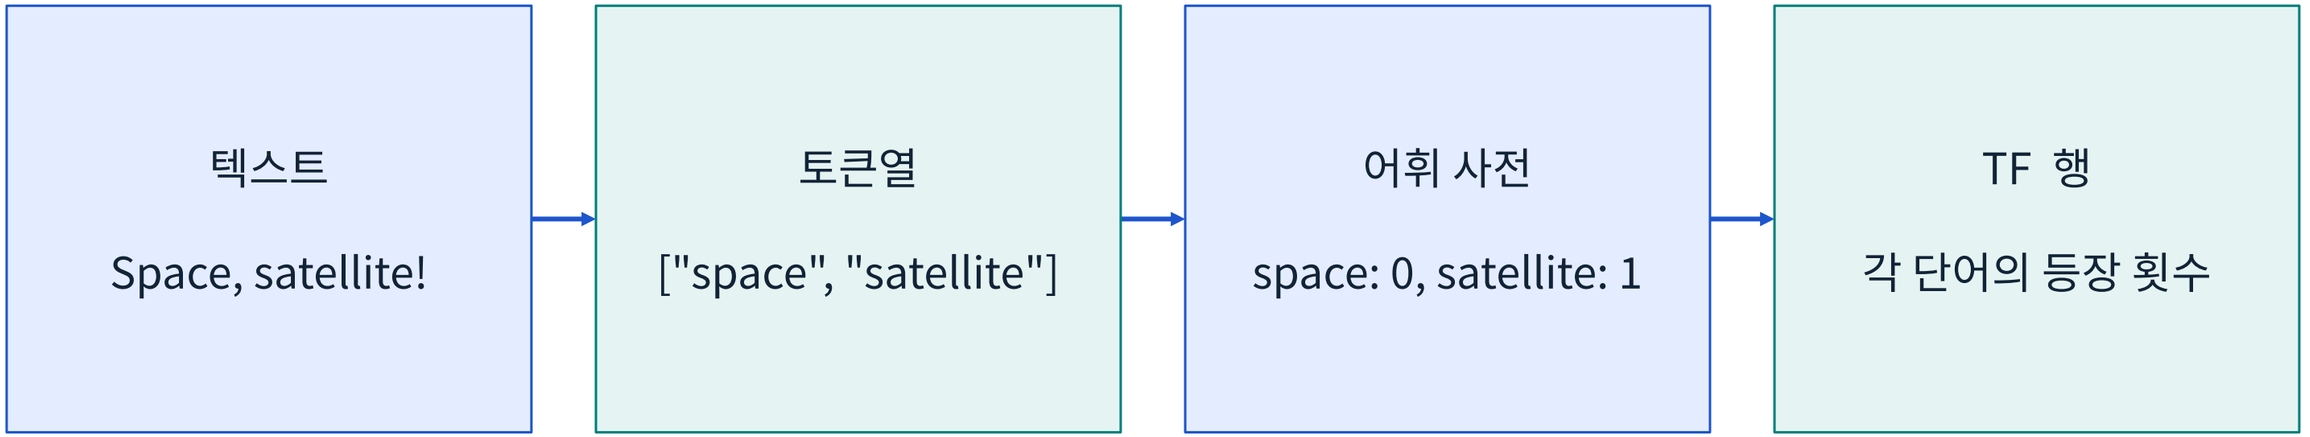
00. A4_1 미션 학습 Q&A

TF-IDF 직접 구현 · 검색 · 분류
Q1–Q5 의 개념과 구현을 연결하는 기술 해설

A4_1 · NumPy TF-IDF 검색과 분류
2026-11-12 문서 및 실측 기준

Q1-1. 토큰화와 빈도 행렬

문자를 집계 가능한 단위로 바꾸는 과정



토큰의 역할 문서를 동일한 기준으로 나누면 문서별 단어 수를 세고 , 같은 어휘 열에서 다른 문서와 비교할 수 있다 .

토큰화와 벡터화 토큰화는 문자열 목록을 만든다 . 학습 어휘의 열을 정하고 빈도를 채우는 작업은 그 다음 벡터화 단계다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q1-2. 실제 토큰 규칙과 경계 사례

소문자화 후 두 글자 이상의 Unicode 단어 추출

```
from src.preprocess import TextPreprocessor
p = TextPreprocessor(stopwords=set())
p.tokenize("Space, SATELLITE! a 3D_x")
# ["space", "satellite", "3d_x"]

#  사용하는 정규식
r"(?u)\b\w\w+\b"
```

남는 정보

숫자와 밑줄도 단어 문자에 포함된다 . 3D_x 는 소문자화된 3d_x 로 남고 , 한 글자인 a 는 제거된다 .

손실 가능성

한 글자 언어명 R, 기호가 핵심인 C++ 는 사라질 수 있다 . 정규식이 모든 전문 용어를 보존하지는 않는다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q1-3. 언어별 토큰화와 OOV

구분	처리와 의미	이 프로젝트의 상태
영어	공백 · 구두점 및 단어 패턴 활용	소문자화 + 정규식 + 불용어
한국어	학교 · 학교에 · 학교에서의 형태 고려	형태소 분석은 후속 실험 대상
OOV	학습 어휘에 없는 토큰	벡터 변환에서 제외
검증 기준	같은 토큰열과 어휘 열 사용	NumPy·sklearn 공통 analyzer

구분할 단계 토큰화에 성공한 단어도 Train 어휘에 없으면 OOV 다 . Unicode 지원 자체가 한국어 형태소 분석을 의미하지 않는다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q2-1. TF 와 DF 가 세는 대상

한 문서 안의 반복과 코퍼스 전체의 분포

기호	정의	설명용 예
TF(d,t)	문서 d 에서 단어 t 가 나온 횟수	한 문서에 3 번 등장하면 3
DF(t)	단어 t 를 포함한 Train 문서 수	한 문서에 3 번 나와도 DF 에는 1
N	IDF 를 학습하는 Train 문서 수	실제 프로젝트 N = 3,029
TF-IDF(d,t)	TF(d,t) × IDF(t)	문서 빈도에 코퍼스 가중치 적용

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q2-2. Smooth IDF 의 로그와 가산항

idf(t) = ln((1 + N) / (1 + df(t))) + 1

로그	문서 빈도의 역수 비율을 완만하게 바꾼다 . 드문 단어를 강조하면서 희귀성 차이가 과도하게 커지는 것을 줄인다 .
분자 · 분모의 +1	N 과 DF 를 함께 보정하는 smoothing 이다 . 이번 구현은 sklearn 의 smooth_idf=True 와 같은 정의를 사용한다 .
로그 바깥의 +1	모든 Train 문서에 있는 단어도 IDF 가 1 이 된다 . 이런 단어의 가중치를 0 으로 만들지 않는다 .

N = 2 일 때 DF = 1 이면 1.405465, DF = 2 이면 1

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q2-3. 두 문서의 TF-IDF 계산

설명용 예제 : 열 순서 $[t_1, t_2]$

설명용 두 문서 : d_1 = “cat cat dog”, d_2 = “dog” 어휘 열 순서 : [cat, dog]

1. 빈도 TF

문서	cat	dog
d_1	2	1
d_2	0	1

× IDF
[1.405465, 1]

2. 원소별 곱

문서	cat	dog
d_1	2.810930	1
d_2	0	1

3. 행별 L2 정규화

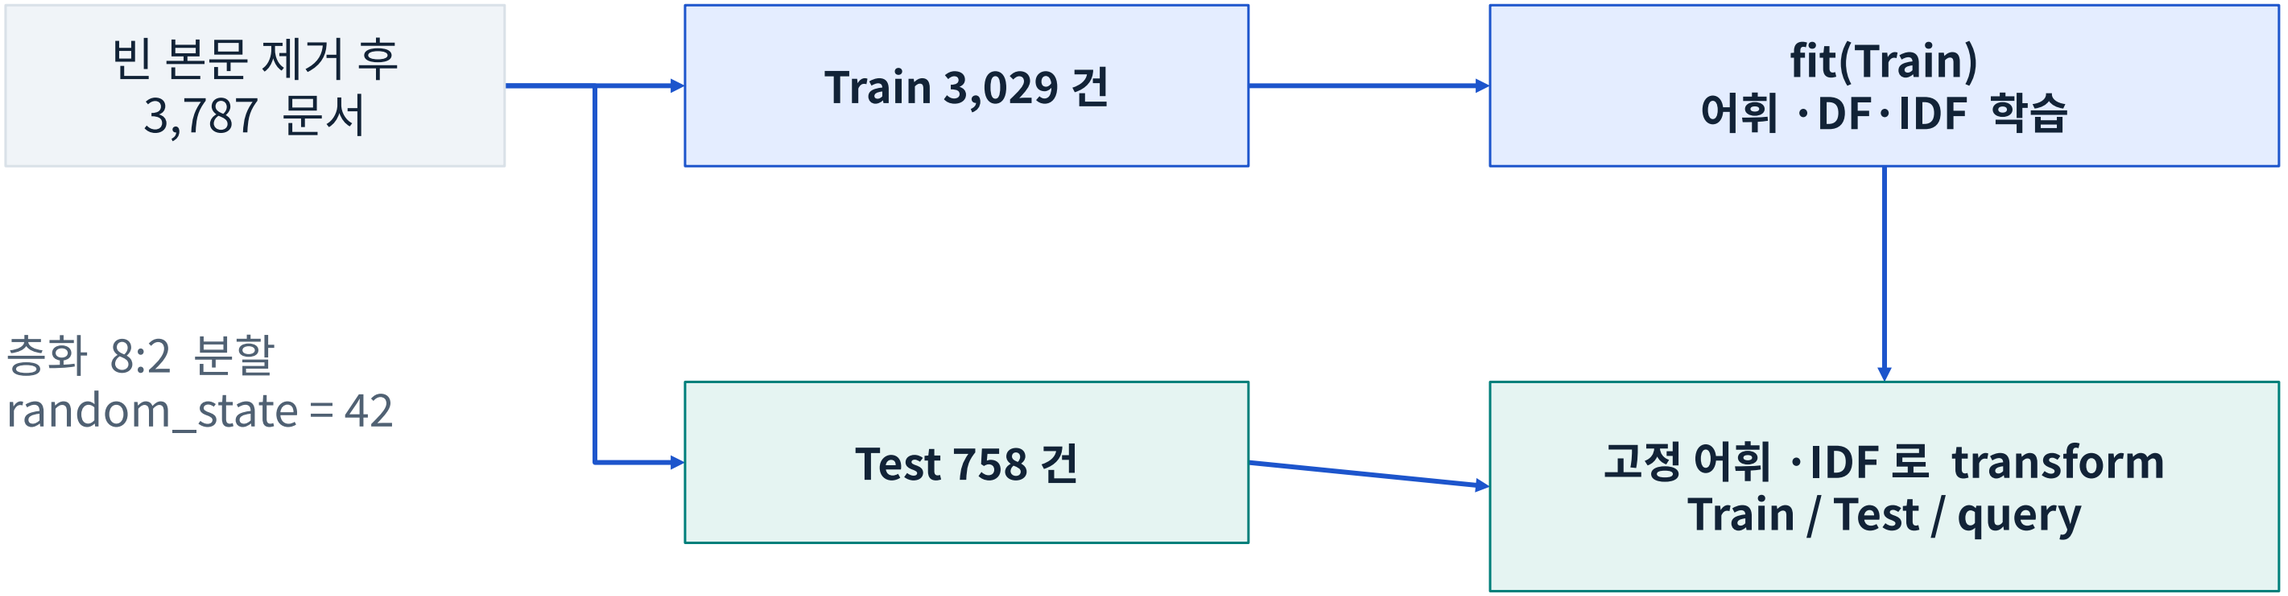
문서	정규화 벡터
d_1	[0.942156, 0.335176]
d_2	[0, 1]

DF = [1, 2], N = 2 이므로 IDF(cat) = ln(3/2) + 1. d_1 의 L2 길이는 2.983509 이다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q2-4. fit 과 transform 의 책임

Train 에서 학습한 어휘와 IDF 를 고정해 재사용



Test 를 fit 에 넣으면 어휘 선택과 IDF 에 평가 데이터의 분포가 섞인다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q2-5. 문서 행렬과 질의 벡터의 shape

D_train	D_test	q
3,029 × 33,297	758 × 33,297	33,297

행은 문서 , 열은 Train 에서 확정한 단어 좌표이다 .

Test 와 query 도 동일한 열 순서를 사용한다 . OOV 단어는 새 열을 만들지 않는다 .
배치 쿼리 1 건은 (1, 33,297), 검색에 넘기는 단일 벡터는 (33,297,) 이다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q2-6. sklearn 참조 설정과 검증 결과

원문 실측 기준 2026-11-12

비교 대상	최대 절대 오차	판정
Train 3,029 건	2.3315e−15	허용 기준 1e−6 이내
Test 758 건	8.3267e−16	허용 기준 1e−6 이내
검증 질의 5 건	0	일치
IDF	0	일치

같은 설정 공통 analyzer, float64, smooth_idf=True, sublinear_tf=False, norm='l2' 로 비교 조건을 맞춘다 .

검증 순서 토큰과 어휘 열 순서를 확인한 뒤 TF·DF·IDF 와 최종 벡터를 비교한다 . 값만 비슷한 다른 열 배열은 통과시키지 않는다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q3-1. 코사인 유사도의 수치 예제

$$\cos(x,q) = (x \cdot q) / (\|x\|_2 \ \|q\|_2)$$

$$x = [3,4],\ q = [0,2]$$
$$\text{내적} = 8,\ \text{길이 곱} = 5 \times 2 = 10$$
$$\cos(x,q) = 0.8$$

비교하는 정보 벡터가 향하는 방향을 비교한다 . 특정 단어 가중치가 함께 큰 문서와 질의는 내적이 커진다 .

미리 정규화 문서와 질의를 각각 길이 1 로 만들면 분모가 1 이 되어 , 검색 시 정규화 벡터의 내적만 계산하면 된다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q3-2. 길이 정규화와 영벡터

$$x_norm = x / \|x\|_2$$
$$\|x_norm - q_norm\|_2^2 = 2 - 2\cos(x,q)$$

유클리드 거리와의 관계	두 벡터가 모두 단위 벡터라면 코사인이 클수록 유클리드 거리는 작다 . 같은 순위를 만들 수 있다 .
0 으로 나누지 않기	빈 문서나 OOV 만 있는 질의는 길이가 0 이다 . 분모가 0 인 행을 나누지 않고 전체 값을 0 으로 유지한다 .
검색 결과	영벡터 질의는 모든 문서와 내적이 0 이다 . 검색기는 양수 점수만 반환하므로 결과는 빈 리스트다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q3-3. D @ q 의 문서별 점수 계산

원문의 두 단어 예제를 이용한 설명용 계산

D (N × |V|) @ q (|V|,) = scores (N,)

문서	cat	dog
d_1	0.942156	0.335176
d_2	0	1

@

q(cat)
1
0

=

문서	점수
d_1	0.942156
d_2	0

문서와 쿼리는 이미 L2 정규화돼 있다 . 한 번의 행렬 · 벡터 곱이 모든 문서와의 코사인 유사도를 구한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q3-4. Top-K 경계와 동점 처리

```
scores = [0, 0.8, 0.8, 0.1]
rank_scores(scores, top_k=1)  # [1]
rank_scores(scores, top_k=9)  # [1, 2, 3]

#  순위 규칙
# 1.  점수가 양수인 후보
# 2.  점수 내림차순
# 3.  동점은 문서 ID 오름차순
```

부분 선택

후보가 K 보다 많으면 K 번째 경계 점수를 찾는다 . 경계와 동점인 후보를 함께 남긴 뒤 최종 순서를 정한다 .

반환 규격

각 항목은 점수 , Train 문서 ID, 최대 150 자 스니펫이다 . 양수 후보가 K 보다 적으면 실제 후보 수만 반환한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q3-5. 검색 인덱스의 저장과 재사용

실행 경로	저장 형식	재사용 방식
소스 CLI	artifacts/index.pkl	SearchEngine 객체 저장 · 로드
단일 노트북	JSON 메타데이터 + NPY 행렬	행렬을 mmap 으로 재로딩
동치성 확인	저장 전후 검색 결과	같은 질의의 점수 · 순위 비교

같이 유지할 정보 문서 벡터뿐 아니라 어휘와 IDF 도 같아야 한다 . 질의를 다른 어휘 순서로 변환하면 저장한 문서와 비교할 수 없다 .

실제 우주 질의 space satellite launch orbit 의 Top-5 ID 는 1934, 2609, 755, 2145, 1725 이며 첫 점수는 약 0.4737 이다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q3-6. 백만 문서 검색의 메모리와 연산

Dense float64 메모리 = $8N|V|$ bytes
$N = 10^6$, $|V| = 50{,}000$
$8 \times 10^6 \times 50{,}000 = 400$ GB ≈ 372.5 GiB

전체 스캔 Dense 행렬은 질의마다 $O(N|V|)$ 내적을 수행한다. 위 메모리는 배열 원소만 계산해 객체와 인덱스 비용은 제외한다.

희소 저장과 역색인 0 이 아닌 가중치와 질의 단어의 posting 을 처리한다. 현재 구현은 전체 점수 배열 초기화에 $O(N)$ 이 추가된다.

확장 검증 메모리와 구축 시간, 질의 지연 p50·p95, 동시성, 갱신 비용을 측정해야 한다. 백만 문서의 실측은 없다.

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-1. BoW 가 구분하지 못하는 정보

한계	설명용 예	벡터에 남는 정보
어순 소실	dog bites man / man bites dog	같은 unigram 빈도
부정어 제거	not good / good	not 제거 후 good 만 남음
다의어	과일 사과 / 용서의 사과	같은 표면형은 같은 열
동의어	표현이 다른 유사 의미	다른 단어 열로 분리

해석 범위 같은 단어 빈도라면 같은 IDF 를 곱한 TF-IDF 도 같다 . 위 문장은 표현의 한계를 설명하는 구성 예제다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-2. 선형 분류기의 단어 기여도

$$z_c = b_c + \Sigma_t x_t w_{c,t}$$
$$\Delta = z_{\text{예측}} - z_{\text{실제}}$$
$$= (b_{\text{예측}} - b_{\text{실제}}) + \Sigma_t x_t (w_{\text{예측},t} - w_{\text{실제},t})$$

기여도의 부호

양수 단어 기여는 예측 클래스를 지지하고 , 음수 기여는 실제 클래스를 지지한다 . 절편 차이도 점수에 더해진다 .

한계

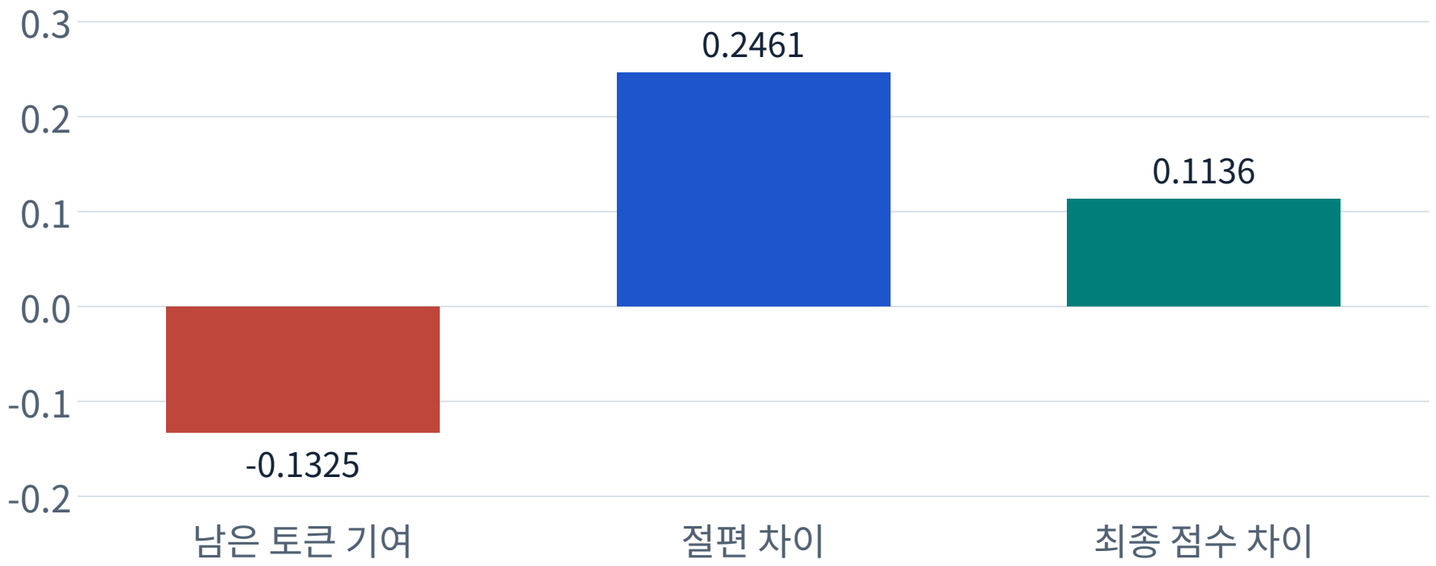
각 기여는 선형 점수 단위다 . 단어 하나의 부호를 실제 원인의 확정 증거나 확률 차이로 해석하지 않는다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-2b. Test ID 25 의 기여도 분해

한 토큰의 기여와 절편 차이를 더하면 최종 점수 차이가 된다

$$s_pred - s_true = \Sigma_j x_j (w_pred,j - w_true,j) + (b_pred - b_true)$$



Test ID 25

정답 : 중동 정치
예측 : 우주

전처리 후 한 토큰만 남았다 .
토큰의 정답 지지보다
절편 차이가 더 컸다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-3. 실제 오분류 다섯 건

원문 실측의 실제 클래스와 예측 클래스

Test ID	실제 / 예측	핵심 기여와 해석
3	중동 정치 / 우주	idea +0.2409, 절편 +0.2461; Δ +0.0123
5	그래픽 / 우주	system +0.1815, base +0.0935; Δ +0.4278
13	그래픽 / 야구	가린 서명 +0.2122, think +0.1741; Δ +0.2199
19	야구 / 우주	si +0.1221, date +0.0700; Δ +0.0233
25	중동 정치 / 우주	토큰 − 0.1325, 절편 +0.2461; Δ +0.1136

공통 관찰 짧은 글 , 약어와 범용 단어 , 잔존 서명 , 전처리 후 부족해진 주제어를 확인했다 . 개선 효과는 아직 가설이다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-4. 혼동 행렬과 분류 지표

행은 실제 클래스 , 열은 예측 클래스 · 원문 실측

예측 클래스

실제 클래스	그래픽	야구	우주	중동 정치
그래픽	179	4	8	0
야구	4	177	10	1
우주	5	5	178	3
중동 정치	1	8	8	167

92.4802%

701 / 758 건 정답
Macro-F1 0.925329

우주로 잘못 예측한 문서
8 + 10 + 8 = 26 건

세로는 정답 , 가로는 예측이다 . 대각선 밖의 57 건이 오분류다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-4b. Precision · Recall · F1 의 계산

혼동 행렬을 한 클래스 대 나머지의 이진 문제로 읽는다

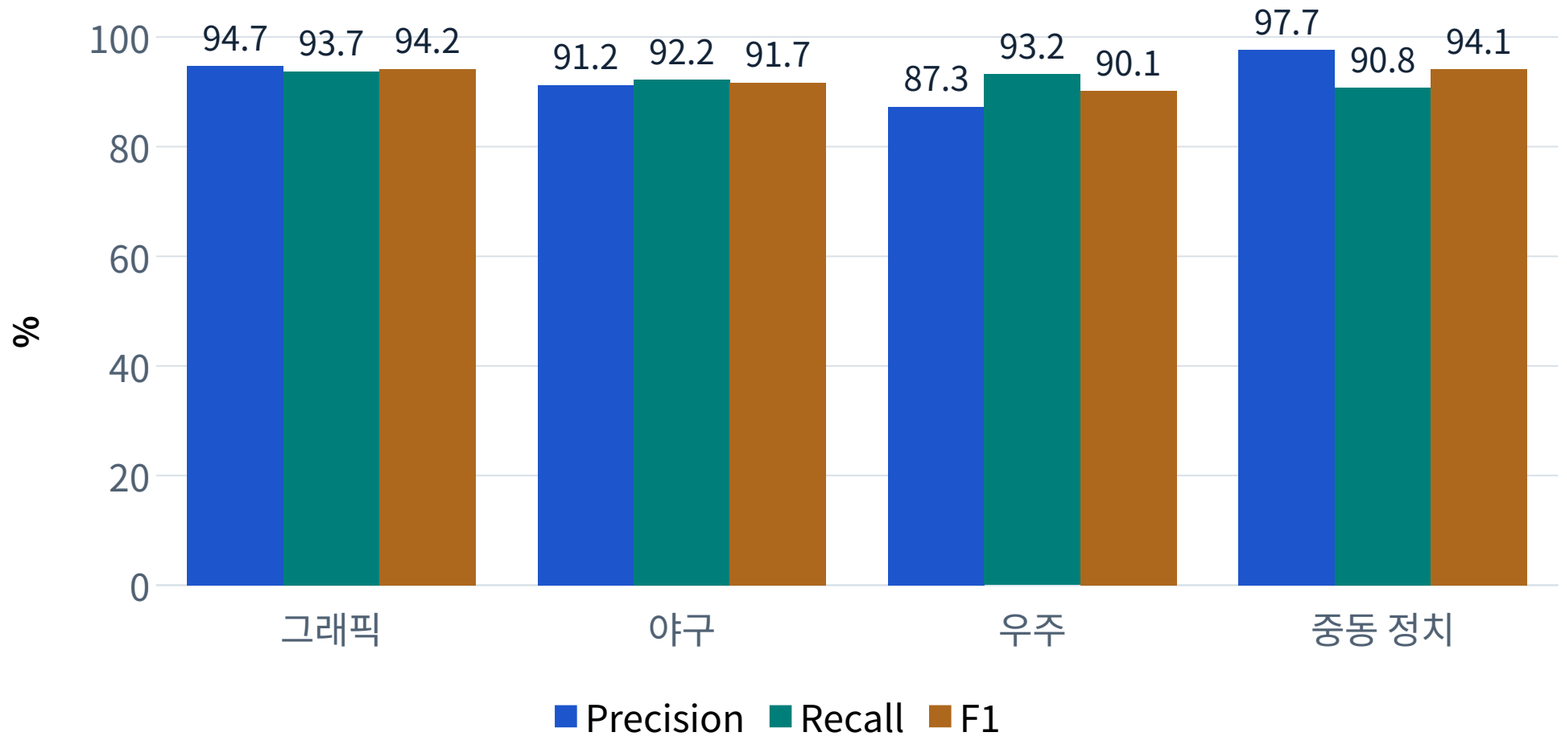
Precision = TP / (TP + FP)
Recall = TP / (TP + FN)
F1 = 2 × Precision × Recall / (Precision + Recall)

우주 클래스로 읽기	TP = 178, FP = 26, FN = 13. 우주 예측 204 건 중 178 건이 정답이고 , 실제 우주 191 건 중 178 건을 맞혔다 .
Macro-F1	각 클래스별로 F1 을 계산한 뒤 네 값을 같은 비중으로 평균한다 . 이 실측에서는 0.925329 이다 .
Accuracy	대각선의 정답 수를 전체 Test 수로 나눈다 . (179 + 177 + 178 + 167) / 758 = 92.4802%.

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-4c. 클래스별 분류 성능

전체 정확도와 별도로 어느 클래스에서 오류가 늘어나는지 본다



우주 클래스

Precision 87.25%
Recall 93.19%
F1 90.13%

우주 문서를 많이 찾지만 다른 주제도 우주로 예측한 사례가 있다 .

Macro-F1 은 네 클래스 F1 의 산술평균이다 . 표본 수로 가중한 평균과 구분한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-5. ‘ 사과’ 검색의 의미 구분

의미가 섞이는 이유

과일 · 기업 · 용서의 의미가 같은 단어 열에 누적될 수 있다 .
단일 단어 질의만으로 사용자의 의도를 확정하기 어렵다 .

비교할 개선안

주변 구문을 담는 bigram, 질의 확장 , 문맥 임베딩을 비교한다 .
의도가 불명확하면 의미 선택을 받는 방법도 가능하다 .

한국어 ‘사과’는 구성 예제이며 , 현재 영문 데이터셋의 실측 결과가 아니다

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q4-6. 검색 관련도와 계산 검증

Precision@5 = Top-5 의 관련 문서 수 / 5
DCG@K = Σ(i=1…K) (2^(rel_i) − 1) / $\log_2$(i + 1)
nDCG@K = DCG@K / IDCG@K

설명용 사례	Top-5 중 4 건이 관련 문서이면 Precision@5 는 0.8 이다 . nDCG 는 관련도 등급과 상위 순위의 중요도를 반영한다 .
현재 측정 범위	관련도 정답셋 기반 Precision@5·nDCG@5 의 실측은 없다 . sklearn 오차와 역색인 순위 일치는 계산 검증이다 .
후속 비교	정답 질의와 관련도 기준을 고정하고 unigram·bigram·BM25· 문맥 모델의 품질과 질의 지연을 함께 비교한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q5-1. 고정 전처리의 효과와 손실

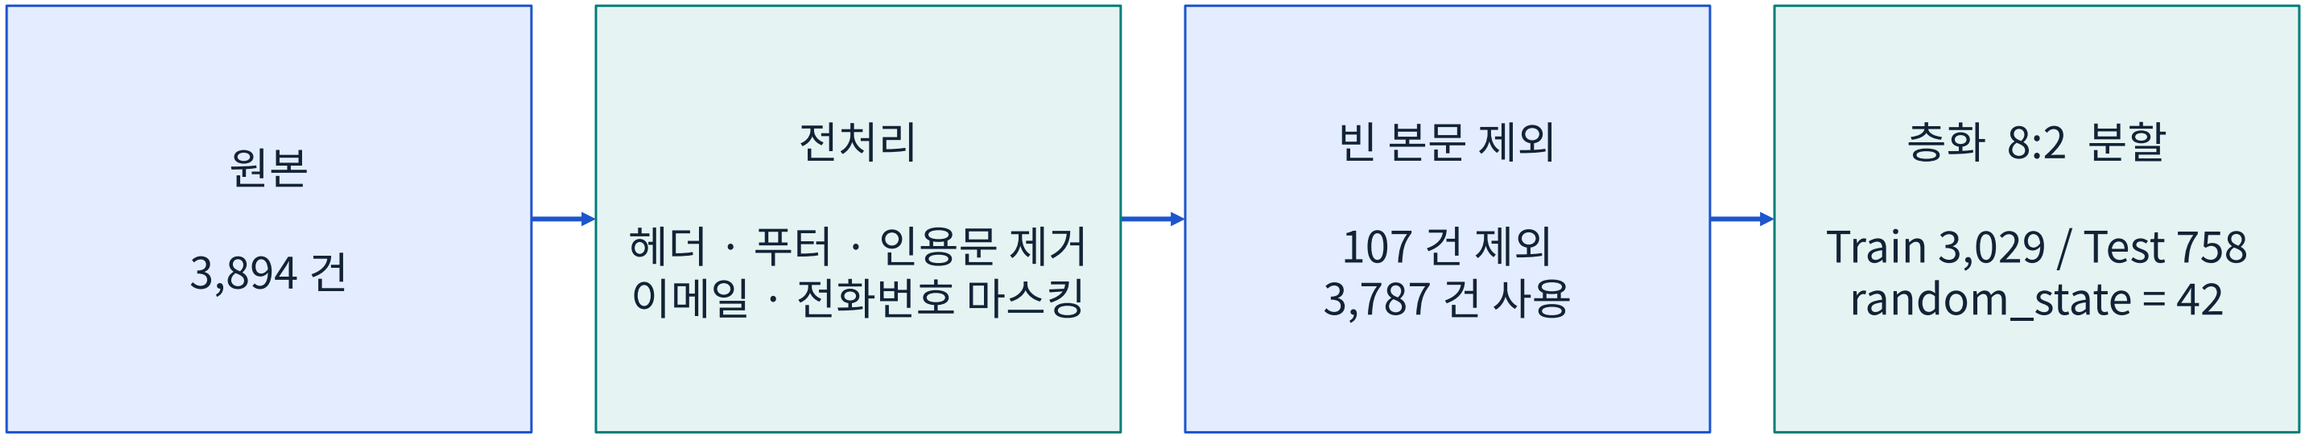
규칙	목적	확인할 손실
소문자화	대소문자 표기 변동 통합	대문자에 담긴 고유명사 단서
두 글자 이상 토큰	짧은 잡음 감소	R·C++ 등 도메인 용어
불용어 123 개	흔한 기능어 감소	no·nor·not 의 부정 의미
정책 고정	실험과 참조 비교 재현	변경 전후 별도 성능 비교

목록의 기준 사용자 제공 목록을 a4-1-en-v1 로 고정하고 정규화 해시를 기록했다 . 외부 목록의 원출처는 미확인이다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q5-2. 데이터 준비와 고정 분할

20 Newsgroups 네 범주의 원문 기록



Test 분포 그래픽 191 건 , 야구 192 건 , 우주 191 건 , 중동 정치 184 건이다 . 분할과 코퍼스 해시를 메타데이터에 기록한다 .

데이터 검수 배포 항목의 CC BY 4.0 과 출처를 기록했다 . 이메일 · 전화번호 마스킹 외에 전체 인명 · 서명의 수동 검수는 남아 있다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q5-3. 모듈 경계와 데이터 교체

모듈	입력과 책임	출력
dataset	데이터 읽기 · 마스킹 · 분할	문서 · 레이블 · 클래스 이름
preprocess	문자열의 공통 토큰화	토큰열
tfidf	어휘 ·DF·IDF 학습 및 변환	같은 어휘 공간의 벡터
search_engine	문서 · 질의 점수와 순위	점수 · 문서 ID· 스니펫
classifier	Train 학습 ·Test 평가	지표 · 혼동 행렬 · 오류 사례

다른 데이터로 교체 로더의 반환 규격과 tokenizer 계약을 유지하면 이후 로직을 재사용할 수 있다 . 분할 · 어휘 ·IDF· 인덱스는 다시 만든다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

Q5-4. 재현 실행과 독립 노트북

프로젝트 루트에서 .venv Python 을 사용하는 명령

```
python verify_tfidf.py
python main.py --build-index
python main.py --query "space satellite launch orbit" --topk 5
python main.py --train-classifier
python main.py --bonus
```

원문 실행 기록

회귀 검사 59 개 통과와 CLI 종료 코드 0 을 기록했다 . 독립 노트북은 새 커널에서 28 셀 중 코드 14 개를 순서대로 실행했다 .

재현 조건

고정 분할 , 불용어 목록 , 어휘 ·IDF 정의를 유지한다 . 변경 실험에서는 조건과 평가 데이터를 함께 기록한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-1a. Raw · Log · Double TF 의 계산

변형 후에도 같은 IDF 와 L2 정규화 적용

TF 방식	양수 빈도 c 의 변환	설명용 c = 1, 3
Raw	c	1, 3
Log	ln(1 + c)	0.6931, 1.3863
Double	$0.5 + 0.5c / c_{max}$	$c_{max} = 3$ 일 때 0.6667, 1

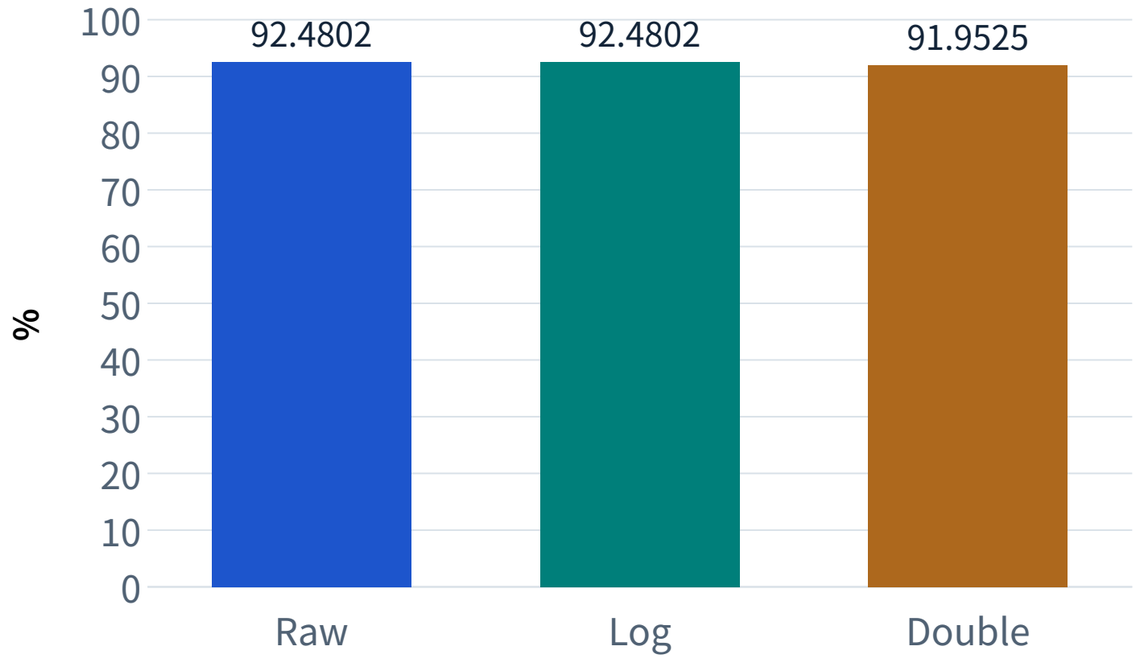
0 빈도 처리 Double 수식은 c>0 에만 적용한다 . 등장하지 않은 단어와 빈 문서의 모든 원소는 0 을 유지한다 .

변형의 의미 Log 는 큰 반복 횟수를 압축하고 Double 은 문서 내부 최댓값에 대해 빈도를 조정한다 . 개선 여부는 실험으로 확인한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-1b. TF 변형의 분류와 검색 결과

동일 분할의 원문 실측



TF	Macro-F1	Top-5 겹침
Raw	0.925329	100%
Log	0.925139	60%
Double	0.919962	40%

동일 분할 · 분류기로 비교한 원문 실측이다 . Top-5 겹침은 우주 질의의 Raw 결과 대비다 . 순위 구성이 달라졌다는 사실만으로 검색 품질 향상을 판단할 수 없다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-2a. BM25 의 TF 포화와 길이 보정

$$IDF(t) = \ln(1 + (N - df(t) + 0.5)/(df(t) + 0.5))$$

$$score(D,Q) = \Sigma_t\, q_t\, IDF(t) \cdot f_{t,D}(k_1 + 1) \,/\, [f_{t,D} + k_1(1 - b + b|D|/avgdl)]$$

TF 포화 단어 빈도 f 가 늘어도 기여가 계속 선형 증가하지 않는다 . k_1 은 반복 빈도에 따른 증가와 포화 정도를 조절한다 .

길이 보정 평균 문서 길이 avgdl 에 대한 |D| 의 비율을 사용한다 . 이 프로젝트는 k_1=1.5, b=0.75 를 사용한다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-2b. BM25 Toy 검증과 반복 질의 정책

질의 [cat, sat], k_1=1.5, b=0.75

설명용 문서	길이	기대 BM25 점수
cat sat sat	3	1.5908508973
cat dog	2	0.4700036292
dog	1	0
독립 수식과의 최대 오차	원문 실측	2.2204e−16

계산에 쓰는 값

N=3, 평균 길이 =2, DF(cat)=2, DF(sat)=1 이다 . 단어의 빈도와 문서 길이를 독립 수식에 대입해 검증했다 .

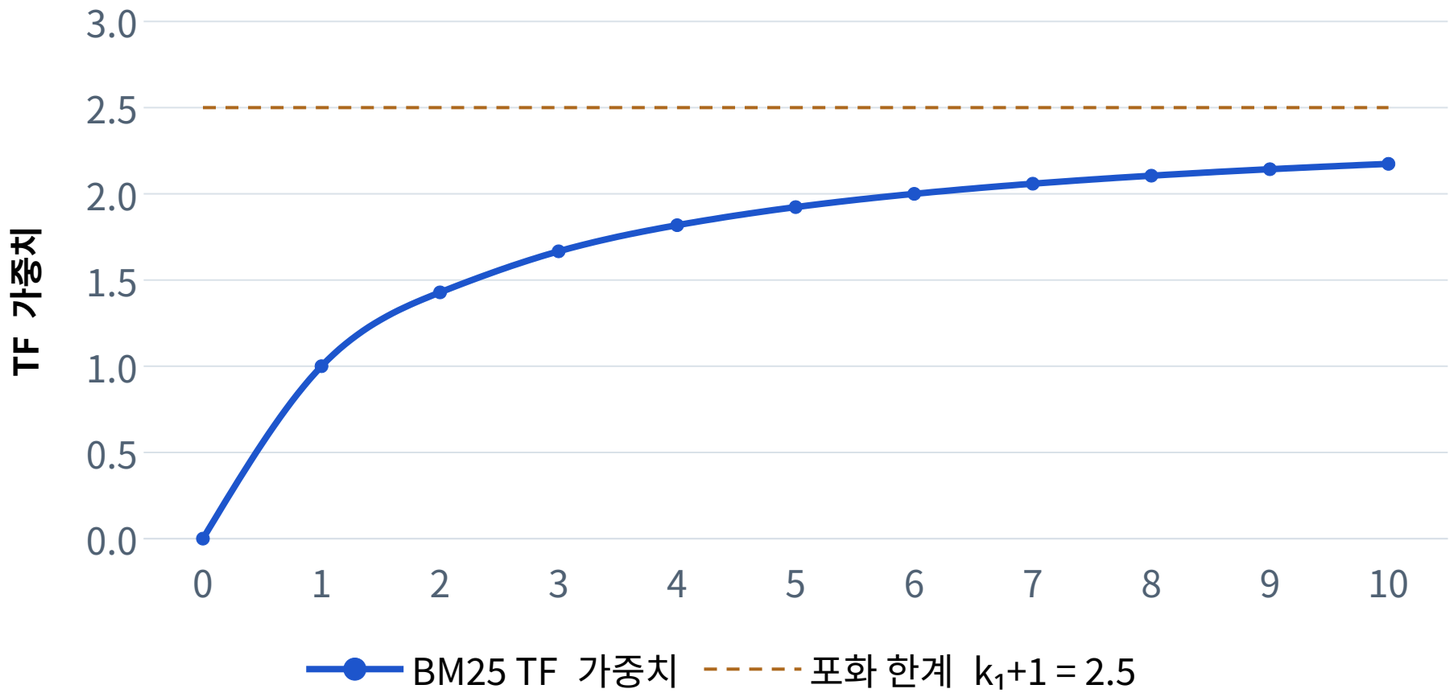
실행 경로 차이

CLI 는 질의 단어의 반복 횟수를 곱한다 . 노트북은 고유 단어를 한 번만 더해 반복 질의의 상호 동치성은 보장하지 않는다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-2c. BM25 의 TF 포화 곡선

단어가 반복될수록 증가폭이 줄어든다



$g(f) = 2.5f / (f + 1.5)$

$k_1 = 1.5$, $|d| = avgdl$ 가정

f = 1 이면 1.0
f = 3 이면 1.667
f 가 커지면 2.5 에 접근

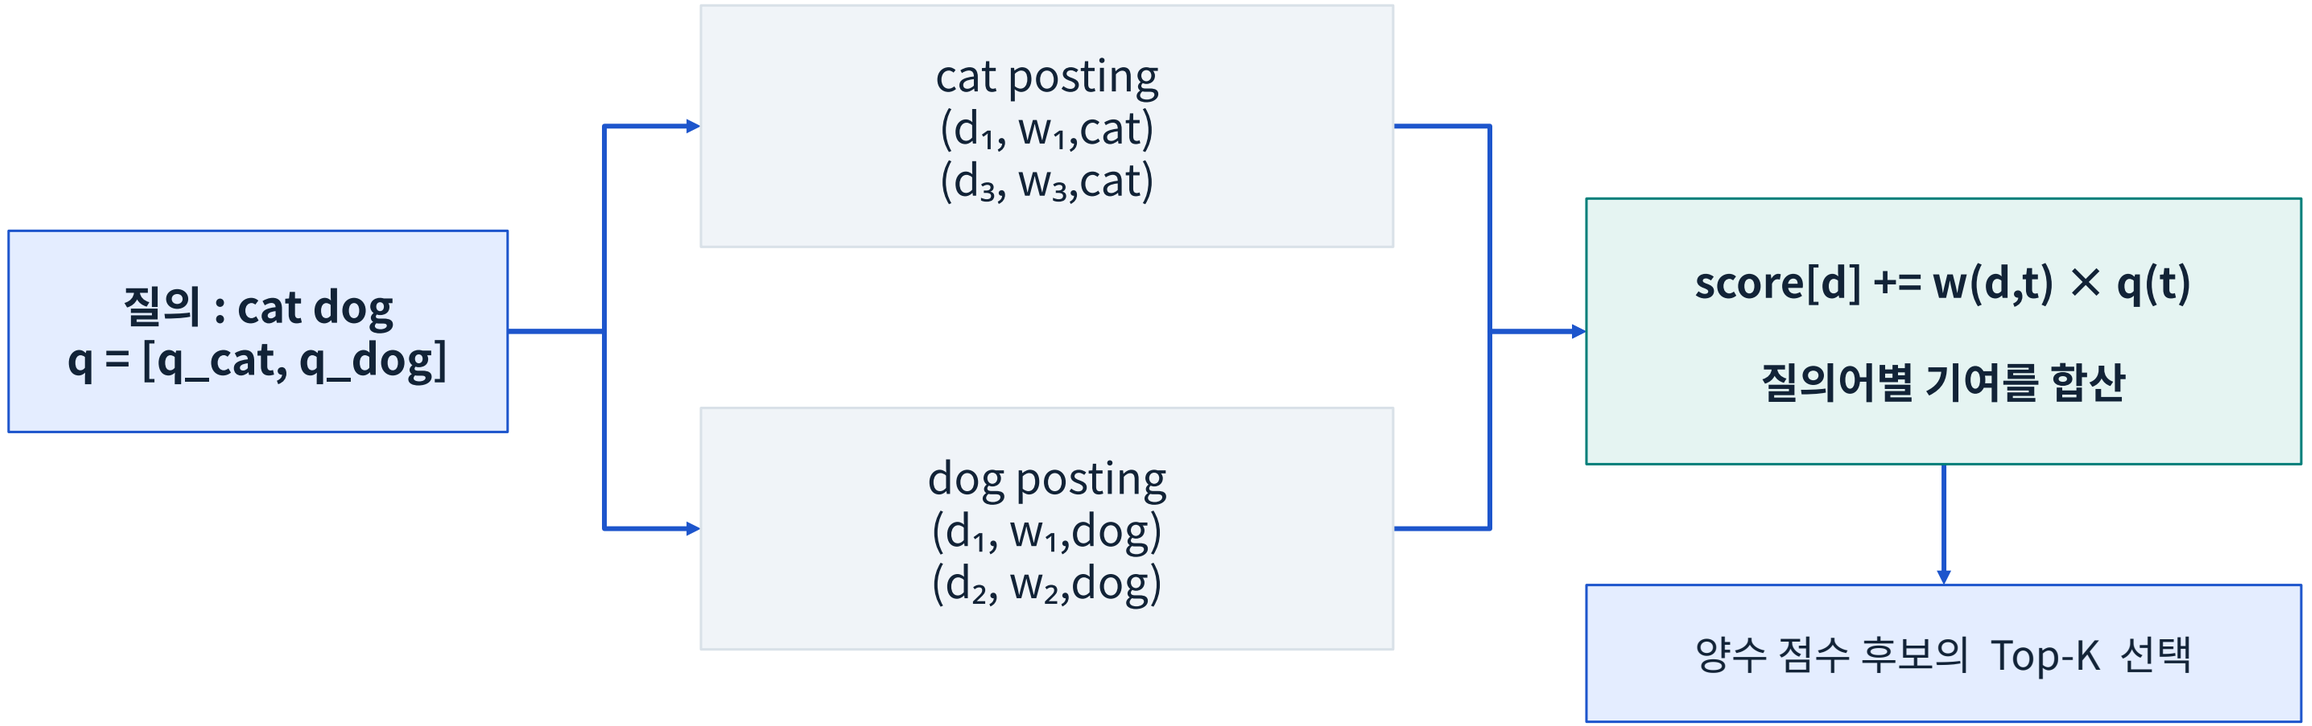
반복 횟수의 추가 기여가
점점 작아진다 .

수식을 시각화한 설명용 계산이다 . 실험 성능이나 검색 관련도 측정값이 아니다 . 가로축은 문서 내 빈도 f 다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-3a. 역색인으로 같은 점수 누적

단어를 기준으로 문서 ID 와 가중치의 posting 저장

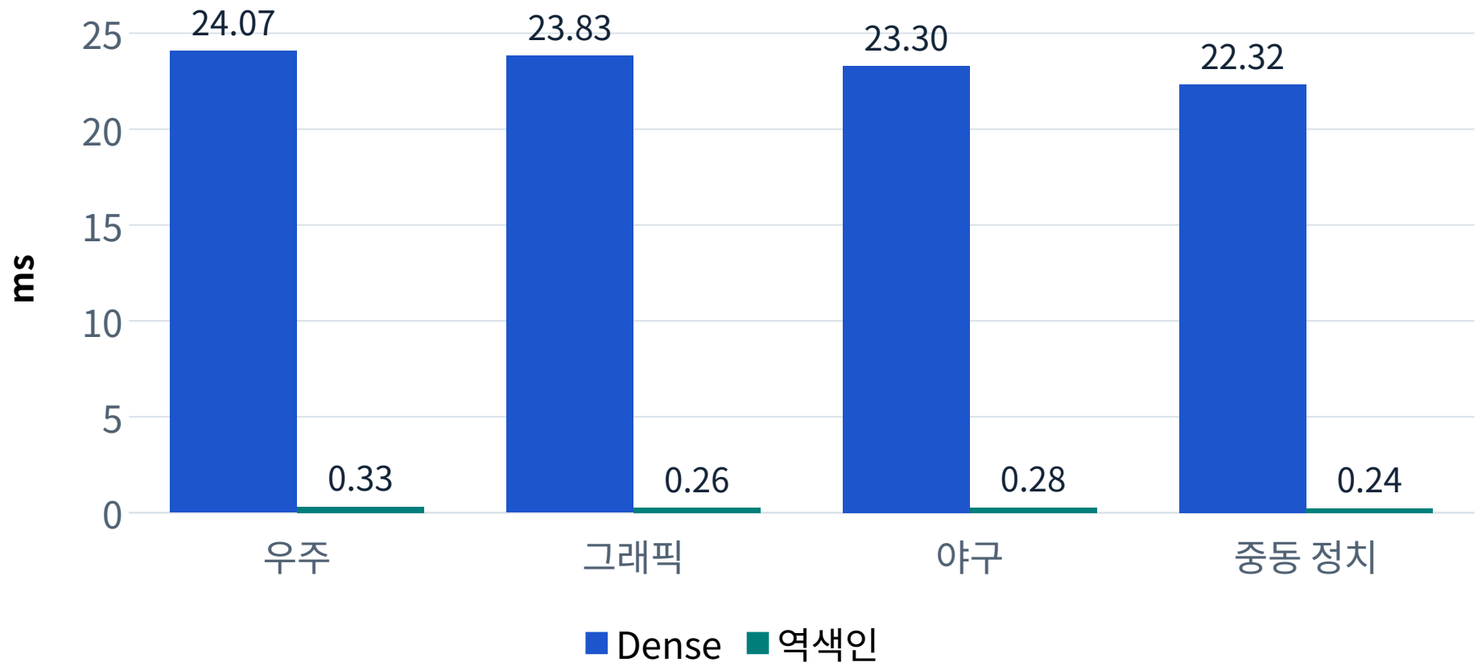


P_Q = Σ df(t). 현재 코드는 길이 N 의 점수 배열을 매 질의 초기화하므로 O(N + P_Q) 와 순위 선택 비용을 가진다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

6-3b. 역색인 동치성과 시간 측정

원문 CLI 측정의 우주 질의 결과



73.3 배

우주 질의의 원문 측정
24.0746 ms / 0.3283 ms

7 개 검증 질의
점수 최대 오차 0
Top-5 순위 모두 일치

점수 계산 · Top-5 선택 포함 , 토큰화 · 벡터화 제외 . BLAS 2 스레드 , 3 회 실행 중앙값 .
인덱스 구축 0.463321 초는 질의 시간과 별도다 . 하드웨어 · 쿼리에 따라 달라진다 .

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장

7-1. 출처와 수치 해석 기준

문서와 실제 구현 , 공개 실측 산출물을 함께 사용했다

문서	docs/A4_1_mission_QnA.md 브랜치 : docs/a4-1-final-readme-qna
구현	src/preprocess.py · src/tfidf.py · src/search_engine.py src/classifier.py · src/bonus/ · A4_1_mission.ipynb
수치와 그림	artifacts/dataset_metadata.json · tfidf_verification.json classifier_metrics.json · bonus_metrics.json · confusion_matrix.png
해석 범위	실측은 저장소의 2026-11-12 기록이다 . 계산 예제는 설명용이다 . 개선 효과와 검색 관련도 지표는 동일 조건의 추가 실험이 필요하다 .

https://github.com/ntt65/A4_1/tree/docs/a4-1-final-readme-qna

근거 : 미션 Q&A 및 저장소 실측 산출물 · 상세 출처는 마지막 장